

## Ejercicio 1

Sea  $A = (a_{ij}) \in \mathbb{C}^{n \times n}$ . Definimos para cada fila  $i$  el disco de Gershgorin

$$D_i = \left\{ z \in \mathbb{C} : |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \right\}.$$

El **Teorema de Gershgorin** establece que *todos los eigenvalores de  $A$  pertenecen a la uni  n de los discos  $D_1, \dots, D_n$* . Adem  s, si un conjunto de  $k$  discos es disjunto de los dem  s, entonces dicho conjunto contiene exactamente  $k$  eigenvalores de  $A$ .

Consideremos la matriz

$$A(\varepsilon) = \begin{pmatrix} 8 & 1 & 0 \\ 1 & 4 & \varepsilon \\ 0 & \varepsilon & 1 \end{pmatrix}, \quad |\varepsilon| \leq 1.$$

Los discos de Gershgorin correspondientes son:

- $D_1$ : centro en 8, radio 1,
- $D_2$ : centro en 4, radio  $1 + |\varepsilon|$ ,
- $D_3$ : centro en 1, radio  $|\varepsilon|$ .

Por el teorema, todos los eigenvalores de  $A(\varepsilon)$  deben encontrarse dentro de la uni  n de estos tres discos.




Figura 1: Discos de Gershgorin para  $\varepsilon = 0,555$ , junto con los eigenvalores exactos de la matriz.

En la Figura 1 observamos que, conforme  $\varepsilon$  aumenta, los discos  $D_2$  y  $D_3$  pueden llegar a solaparse. Cuando  $|\varepsilon| = 1$ , los radios de estos discos alcanzan su m  ximo valor, y  $D_2$  se superpone parcialmente con  $D_3$ . Aun as  , el disco  $D_1$  permanece separado, garantizando la presencia de un eigenvalor cercano a 8. Los discos  $D_2$  y  $D_3$ , al formar un dominio conexo, contienen en conjunto exactamente dos eigenvalores. En total, se recupera as   la localizaci  n de los tres eigenvalores de la matriz.

## Ejercicio 2

El método QR consiste en calcular iterativamente una secuencia de matrices  $A_k$  similares a la matriz inicial  $A_0 = A$ , cuyas diagonales convergen a los eigenvalores de  $A$ .

En cada paso  $k$  de la iteración se realiza la factorización QR:

$$A_{k-1} = Q_k R_k,$$

donde  $Q_k$  es ortogonal y  $R_k$  es triangular superior.

A continuación, se construye la siguiente matriz de la secuencia como

$$A_k = R_k Q_k.$$

Obsérvese que

$$A_k = R_k Q_k = Q_k^\top A_{k-1} Q_k,$$

de modo que  $A_k$  es similar a  $A_{k-1}$  y, por lo tanto, todas las matrices  $A_k$  tienen los mismos eigenvalores que  $A$ .

En nuestra implementación, la factorización QR se realiza de dos maneras:

1. Usando *Gram-Schmidt modificado* (nuestro propio algoritmo).
2. Usando la función `scipy.linalg.qr` de SciPy, como referencia.

En ambos casos, los eigenvalores aproximados se obtienen a partir de las entradas diagonales de  $A_k$  cuando el término fuera de la diagonal cumple

$$\sum_{i \neq j} |(A_k)_{ij}| < \text{tol},$$

donde `tol` es la tolerancia establecida.

Se aplicó el método QR a la matriz

$$A = \begin{bmatrix} 8 & 1 & 0 \\ 1 & 4 & \varepsilon \\ 0 & \varepsilon & 1 \end{bmatrix}, \quad \varepsilon \in \{10^0, 10^{-1}, 10^{-2}, 10^{-4}, 10^{-5}\}.$$

Para ilustrar cómo la iteración QR transforma la matriz en cada paso, mostramos el resultado de las primeras 5 iteraciones para el caso  $\varepsilon = 10^{-1}$ .

Iteración con Gram-Schmidt (propio)

$$A^{(0)} = \begin{bmatrix} 8,1846 & 0,4771 & 5,03 \cdot 10^{-17} \\ 0,4771 & 3,8186 & 2,59 \cdot 10^{-2} \\ 0 & 2,59 \cdot 10^{-2} & 0,9967 \end{bmatrix},$$

$$A^{(1)} = \begin{bmatrix} 8,2253 & 0,2202 & 4,84 \cdot 10^{-17} \\ 0,2202 & 3,7782 & 6,83 \cdot 10^{-3} \\ 0 & 6,83 \cdot 10^{-3} & 0,9965 \end{bmatrix},$$

$$A^{(2)} = \begin{bmatrix} 8,2339 & 0,1009 & 5,02 \cdot 10^{-17} \\ 0,1009 & 3,7696 & 1,80 \cdot 10^{-3} \\ 0 & 1,80 \cdot 10^{-3} & 0,9965 \end{bmatrix}.$$

Iteración con SciPy QR

$$A^{(0)} = \begin{bmatrix} 8,1846 & 0,4771 & -5,20 \cdot 10^{-18} \\ 0,4771 & 3,8186 & -2,59 \cdot 10^{-2} \\ 0 & -2,59 \cdot 10^{-2} & 0,9967 \end{bmatrix},$$

$$A^{(1)} = \begin{bmatrix} 8,2253 & 0,2202 & 5,64 \cdot 10^{-18} \\ 0,2202 & 3,7782 & 6,83 \cdot 10^{-3} \\ 0 & 6,83 \cdot 10^{-3} & 0,9965 \end{bmatrix},$$

$$A^{(2)} = \begin{bmatrix} 8,2339 & 0,1009 & -5,58 \cdot 10^{-18} \\ 0,1009 & 3,7696 & -1,80 \cdot 10^{-3} \\ 0 & -1,80 \cdot 10^{-3} & 0,9965 \end{bmatrix}.$$

Se observa que en ambas variantes, la matriz  $A^{(k)}$  tiende rápidamente a una forma casi triangular, con los eigenvalores apareciendo en la diagonal, no obstante podemos notar que la iteración con Scipy ofrece ya convergencias mayores a la del algoritmo propio.

Los resultados obtenidos se muestran en el Cuadro 1.

| $\varepsilon$ | Eigenvalores teóricos    | Gram-Schmidt             | Scipy QR                 | Error Rel GS          | Error Rel Sp          | Iter GS | Iter Sp |
|---------------|--------------------------|--------------------------|--------------------------|-----------------------|-----------------------|---------|---------|
| 1e+0          | [8.2436, 4.0711, 0.6853] | [8.2436, 4.0711, 0.6853] | [8.2436, 4.0711, 0.6853] | $4,31 \cdot 10^{-16}$ | $7,52 \cdot 10^{-16}$ | 1500    | 1500    |
| 1e-1          | [8.2361, 3.7674, 0.9965] | [8.2361, 3.7674, 0.9965] | [8.2361, 3.7674, 0.9965] | $6,34 \cdot 10^{-16}$ | $9,20 \cdot 10^{-16}$ | 1500    | 1500    |
| 1e-2          | [8.2361, 3.7640, 1.0000] | [8.2361, 3.7640, 1.0000] | [8.2361, 3.7640, 1.0000] | $2,92 \cdot 10^{-16}$ | $6,17 \cdot 10^{-16}$ | 1500    | 1500    |
| 1e-4          | [8.2361, 3.7639, 1.0000] | [8.2361, 3.7639, 1.0000] | [8.2361, 3.7639, 1.0000] | $5,02 \cdot 10^{-17}$ | $3,93 \cdot 10^{-16}$ | 1500    | 48      |
| 1e-5          | [8.2361, 3.7639, 1.0000] | [8.2361, 3.7639, 1.0000] | [8.2361, 3.7639, 1.0000] | $4,17 \cdot 10^{-16}$ | $6,17 \cdot 10^{-16}$ | 1500    | 1500    |

Cuadro 1: Comparación entre la iteración QR con los algoritmos Gram-Schmidt y con SciPy, con una tolerancia de  $1 \times 10^{-16}$  y un máximo de 1,500 iteracciones.

A partir de los resultados podemos concluir que ambos métodos (Gram-Schmidt y SciPy) obtienen los eigenvalores correctos con errores relativos muy pequeños del orden de  $10^{-16}$ , la diferencia radica en la velocidad de convergencia, pues nuestra implementación con Gram-Schmidt requiere prácticamente siempre el máximo de iteraciones permitidas (1500), mientras que la factorización QR de SciPy puede converger mucho más rápido, como ocurre en el caso  $\varepsilon = 10^{-4}$  (48 iteraciones), esto muestra que, aunque la implementación propia es teóricamente correcta, la versión optimizada y numéricamente estable de SciPy es mucho más eficiente en la práctica.